



UNIVERSIDAD AUTÓNOMA DE ZACATECAS.

“FRANCISCO GARCÍA SALINAS.”

UNIDAD ACADÉMICA DE MATEMÁTICAS.

Licenciatura en Actuaría.

ACP DE LA BASE DE DATOS IRIS.

Actividad del Módulo 1.

Materia:

Grandes Bases de Datos.

Alumna:

Ana Camila López Ceballos.

Profesor:

Dr. José Raúl Castro Esparza.

Zacatecas, Zac.

2026

1. Introducción.

En esta actividad se realizó un Análisis de Componentes Principales (PCA) utilizando la base de datos Iris. El objetivo fue reducir la dimensionalidad de los datos y determinar qué porcentaje de la información original puede conservarse utilizando únicamente los primeros componentes principales.

2. Base de datos Iris.

2.1. Carga de la base de datos.

```
# Tratamiento de datos
import numpy as np
import pandas as pd

# Graficos
import matplotlib.pyplot as plt

# Preprocesado y modelo
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import make_pipeline
from numpy import linalg as LA
```

```
df = pd.DataFrame(
    np.array([
        [5.1,3.5,1.4,.2,'Setosa'],
        [4.9,3,1.4,.2,'Setosa'],
        [4.7,3.2,1.3,.2,'Setosa'],
        [4.6,3.1,1.5,.2,'Setosa'],
        [5,3.6,1.4,.2,'Setosa'],
        [5.4,3.9,1.7,.4,'Setosa'],
        [4.6,3.4,1.4,.3,'Setosa'],
        [5,3.4,1.5,.2,'Setosa'],
        [4.4,2.9,1.4,.2,'Setosa'],
        [4.9,3.1,1.5,.1,'Setosa'],
        [5.4,3.7,1.5,.2,'Setosa'],
        [4.8,3.4,1.6,.2,'Setosa'],
        [4.8,3,1.4,.1,'Setosa'],
        [4.3,3,1.1,.1,'Setosa'],
        [5.8,4,1.2,.2,'Setosa'],
        [5.7,4.4,1.5,.4,'Setosa'],
        [5.4,3.9,1.3,.4,'Setosa'],
        [5.1,3.5,1.4,.3,'Setosa'],
        [5.7,3.8,1.7,.3,'Setosa'],
        [5.1,3.8,1.5,.3,'Setosa'],
        [5.4,3.4,1.7,.2,'Setosa'],
        [5.1,3.7,1.5,.4,'Setosa'],
        [4.6,3.6,1,.2,'Setosa'],
```

```

[5.1,3.3,1.7,.5,'Setosa'],
[4.8,3.4,1.9,.2,'Setosa'],
[5,3,1.6,.2,'Setosa'],
[5,3.4,1.6,.4,'Setosa'],
[5.2,3.5,1.5,.2,'Setosa'],
[5.2,3.4,1.4,.2,'Setosa'],
[4.7,3.2,1.6,.2,'Setosa'],
[4.8,3.1,1.6,.2,'Setosa'],
[5.4,3.4,1.5,.4,'Setosa'],
[5.2,4.1,1.5,.1,'Setosa'],
[5.5,4.2,1.4,.2,'Setosa'],
[4.9,3.1,1.5,.2,'Setosa'],
[5,3.2,1.2,.2,'Setosa'],
[5.5,3.5,1.3,.2,'Setosa'],
[4.9,3.6,1.4,.1,'Setosa'],
[4.4,3,1.3,.2,'Setosa'],
[5.1,3.4,1.5,.2,'Setosa'],
[5,3.5,1.3,.3,'Setosa'],
[4.5,2.3,1.3,.3,'Setosa'],
[4.4,3.2,1.3,.2,'Setosa'],
[5,3.5,1.6,.6,'Setosa'],
[5.1,3.8,1.9,.4,'Setosa'],
[4.8,3,1.4,.3,'Setosa'],
[5.1,3.8,1.6,.2,'Setosa'],
[4.6,3.2,1.4,.2,'Setosa'],
[5.3,3.7,1.5,.2,'Setosa'],
[5,3.3,1.4,.2,'Setosa'],

[7,3.2,4.7,1.4,'Versicolor'],
[6.4,3.2,4.5,1.5,'Versicolor'],
[6.9,3.1,4.9,1.5,'Versicolor'],
[5.5,2.3,4,1.3,'Versicolor'],
[6.5,2.8,4.6,1.5,'Versicolor'],
[5.7,2.8,4.5,1.3,'Versicolor'],
[6.3,3.3,4.7,1.6,'Versicolor'],
[4.9,2.4,3.3,1,'Versicolor'],
[6.6,2.9,4.6,1.3,'Versicolor'],
[5.2,2.7,3.9,1.4,'Versicolor'],
[5,2,3.5,1,'Versicolor'],
[5.9,3,4.2,1.5,'Versicolor'],
[6,2.2,4,1,'Versicolor'],
[6.1,2.9,4.7,1.4,'Versicolor'],
[5.6,2.9,3.6,1.3,'Versicolor'],
[6.7,3.1,4.4,1.4,'Versicolor'],
[5.6,3,4.5,1.5,'Versicolor'],
[5.8,2.7,4.1,1,'Versicolor'],
[6.2,2.2,4.5,1.5,'Versicolor'],
[5.6,2.5,3.9,1.1,'Versicolor'],
[5.9,3.2,4.8,1.8,'Versicolor'],
[6.1,2.8,4,1.3,'Versicolor'],
[6.3,2.5,4.9,1.5,'Versicolor'],

```

[6.1,2.8,4.7,1.2,'Versicolor'],
 [6.4,2.9,4.3,1.3,'Versicolor'],
 [6.6,3,4.4,1.4,'Versicolor'],
 [6.8,2.8,4.8,1.4,'Versicolor'],
 [6.7,3,5,1.7,'Versicolor'],
 [6,2.9,4.5,1.5,'Versicolor'],
 [5.7,2.6,3.5,1,'Versicolor'],
 [5.5,2.4,3.8,1.1,'Versicolor'],
 [5.5,2.4,3.7,1,'Versicolor'],
 [5.8,2.7,3.9,1.2,'Versicolor'],
 [6,2.7,5.1,1.6,'Versicolor'],
 [5.4,3,4.5,1.5,'Versicolor'],
 [6,3.4,4.5,1.6,'Versicolor'],
 [6.7,3.1,4.7,1.5,'Versicolor'],
 [6.3,2.3,4.4,1.3,'Versicolor'],
 [5.6,3,4.1,1.3,'Versicolor'],
 [5.5,2.5,4,1.3,'Versicolor'],
 [5.5,2.6,4.4,1.2,'Versicolor'],
 [6.1,3,4.6,1.4,'Versicolor'],
 [5.8,2.6,4,1.2,'Versicolor'],
 [5,2.3,3.3,1,'Versicolor'],
 [5.6,2.7,4.2,1.3,'Versicolor'],
 [5.7,3,4.2,1.2,'Versicolor'],
 [5.7,2.9,4.2,1.3,'Versicolor'],
 [6.2,2.9,4.3,1.3,'Versicolor'],
 [5.1,2.5,3,1.1,'Versicolor'],
 [5.7,2.8,4.1,1.3,'Versicolor'],

 [6.3,3.3,6,2.5,'Virginica'],
 [5.8,2.7,5.1,1.9,'Virginica'],
 [7.1,3,5.9,2.1,'Virginica'],
 [6.3,2.9,5.6,1.8,'Virginica'],
 [6.5,3,5.8,2.2,'Virginica'],
 [7.6,3,6.6,2.1,'Virginica'],
 [4.9,2.5,4.5,1.7,'Virginica'],
 [7.3,2.9,6.3,1.8,'Virginica'],
 [6.7,2.5,5.8,1.8,'Virginica'],
 [7.2,3.6,6.1,2.5,'Virginica'],
 [6.5,3.2,5.1,2,'Virginica'],
 [6.4,2.7,5.3,1.9,'Virginica'],
 [6.8,3,5.5,2.1,'Virginica'],
 [5.7,2.5,5,2,'Virginica'],
 [5.8,2.8,5.1,2.4,'Virginica'],
 [6.4,3.2,5.3,2.3,'Virginica'],
 [6.5,3,5.5,1.8,'Virginica'],
 [7.7,3.8,6.7,2.2,'Virginica'],
 [7.7,2.6,6.9,2.3,'Virginica'],
 [6,2.2,5,1.5,'Virginica'],
 [6.9,3.2,5.7,2.3,'Virginica'],
 [5.6,2.8,4.9,2,'Virginica'],
 [7.7,2.8,6.7,2,'Virginica'],

```

[6.3,2.7,4.9,1.8,'Virginica'],
[6.7,3.3,5.7,2.1,'Virginica'],
[7.2,3.2,6,1.8,'Virginica'],
[6.2,2.8,4.8,1.8,'Virginica'],
[6.1,3,4.9,1.8,'Virginica'],
[6.4,2.8,5.6,2.1,'Virginica'],
[7.2,3,5.8,1.6,'Virginica'],
[7.4,2.8,6.1,1.9,'Virginica'],
[7.9,3.8,6.4,2,'Virginica'],
[6.4,2.8,5.6,2.2,'Virginica'],
[6.3,2.8,5.1,1.5,'Virginica'],
[6.1,2.6,5.6,1.4,'Virginica'],
[7.7,3,6.1,2.3,'Virginica'],
[6.3,3.4,5.6,2.4,'Virginica'],
[6.4,3.1,5.5,1.8,'Virginica'],
[6.3,4.8,1.8,'Virginica'],
[6.9,3.1,5.4,2.1,'Virginica'],
[6.7,3.1,5.6,2.4,'Virginica'],
[6.9,3.1,5.1,2.3,'Virginica'],
[5.8,2.7,5.1,1.9,'Virginica'],
[6.8,3.2,5.9,2.3,'Virginica'],
[6.7,3.3,5.7,2.5,'Virginica'],
[6.7,3,5.2,2.3,'Virginica'],
[6.3,2.5,5,1.9,'Virginica'],
[6.5,3,5.2,2,'Virginica'],
[6.2,3.4,5.4,2.3,'Virginica'],
[5.9,3,5.1,1.8,'Virginica']
]),

columns=['sepal.length','sepal.width','petal.length','petal.width','variety'])

```

df

La base de datos Iris contiene 150 observaciones que corresponde a tres variedades de flores, que son: Setosa, Versicolor y Virginica. Cada observación considera cuatro variables numéricas: longitud y ancho del sépalo, y longitud y ancho del pétalo. La variable **variety** nos permite identificar la especie correspondiente a cada observación.

2.2. Número de observaciones.

```

# Determinar el numero de renglones de la base de datos

index = df.index
renglones = len(index)

renglones

```

150

En este caso verificamos que la base de datos contiene 150 observaciones, las cuales las utilizaremos para realizar el análisis de componentes principales.

2.3. Estandarización de las variables.

```
# Estandarizacion de las variables

df2 = StandardScaler().fit_transform(df.iloc[:,0:4])
df2
```

Antes de realizar el PCA estandarizaremos las cuatro variables que son numéricas. Este procedimiento nos ayudará a trabajar con las variables en una escala comparable, y con esto evitaremos que alguna tenga mayor influencia solamente por la magnitud de sus valores.

2.4. Matriz de correlaciones.

```
# Calcular la matriz de correlaciones para la matriz transformada
A = (1/renglones) * np.dot(df2.T, df2)
A
```

```
[[ 1.0000  -0.1176   0.8718   0.8179]
 [-0.1176   1.0000  -0.4284  -0.3661]
 [ 0.8718  -0.4284   1.0000   0.9629]
 [ 0.8179  -0.3661   0.9629   1.0000]]
```

En la matriz de correlaciones podemos observar que la longitud y el ancho del pétalo tiene una relación positiva fuerte, ya que tiene una correlación aproximada de 0.963. También hay una relación positiva entre la longitud del sépalo y la longitud del pétalo, y también entre la longitud del sépalo y el ancho del pétalo.

Estas relaciones nos dicen que existe información que se comparte entre las variables, por lo que nos resulta adecuado aplicar un ACP para resumir esa información en un menor número de componentes.

2.5. Eigenvalores.

```
# Entrenamiento del modelo PCA con escalado de los datos
pca_pipe = make_pipeline(StandardScaler(),PCA())
pca_pipe.fit(df.iloc[:,0:4])

# Se extrae el modelo entrenado del pipeline
modelo_pca = pca_pipe.named_steps['pca']

print('Eigenvalores:')
results = LA.eigvals(A)
print(results)
```

Eigenvalores:

```
[2.91849782 0.91403047 0.14675688 0.02071484]
```

El primer componente presenta el valor más grande, con aproximadamente 2.918, seguido por el segundo componente con 0.9140. Los componentes restantes tienen valores considerablemente menores, por lo que nos aportan menos información en el análisis.

2.6. Porcentaje de varianza explicada.

```
# Porcentaje de la varianza explicada por cada nuevo componente
print("Porcentaje de varianza explicada por componente")
print(modelo_pca.explained_variance_ratio_)
```

Porcentaje de varianza explicada por componente

```
[0.72962445 0.22850762 0.03668922 0.00517871]
```

Nuestro primer componente principal nos explica aproximadamente el 72.96 % de la variabilidad total de los datos, y el segundo nos explica un 22.85 %.

Si usamos los dos primeros componentes conservamos alrededor del 95.81 % de la variabilidad total de los datos.

Entonces, si nos fue posible representar las 4 variables en solo dos componentes y conservamos la mayor parte de la información contenida en los datos.

2.7. Cálculo de Eigenvectores.

```
# Calculo de eigenvectores

print('Eigenvectores (por renglon):')

pd.DataFrame(
    data = modelo_pca.components_,
    columns = df.columns[0:4],
    index = ['PC1', 'PC2', 'PC3', 'PC4'])
```

	sepal.length	sepal.width	petal.length	petal.width
PC1	0.521066	-0.269347	0.580413	0.564857
PC2	0.377418	0.923296	0.024492	0.066942
PC3	0.719566	-0.244382	-0.142126	-0.634273
PC4	-0.261286	0.123510	0.801449	-0.523597

En el primer componente, las variables que más influyen son la longitud y el ancho del pétalo, además de la longitud del sépalo. Esto quiere decir que el PC1 está relacionado principalmente con el tamaño de estas partes de la flor.

En el segundo componente, la variable que más destaca es el ancho del sépalo, ya que tiene un valor de 0.9233.

2.8. Proyecciones de los componentes.

```
# Proyecciones de los componentes
```

```
proyecciones = np.dot(modelo_pca.components_,df2.T)
```

```
proyecciones = pd.DataFrame(proyecciones,index['PC1','PC2','PC3','PC4'])
```

```
proyecciones = (proyecciones.transpose().set_index(df.index))
```

```
proyecciones
```

	PC1	PC2	PC3	PC4
0	-2.264703	0.480027	0.127706	-0.024168
1	-2.080961	-0.674134	0.234609	-0.103007
2	-2.364229	-0.341908	-0.044201	-0.028377
3	-2.299384	-0.597395	-0.091290	0.065956
4	-2.389842	0.646835	-0.015738	0.035923

...

145	1.870503	0.386966	-0.256274	-0.389257
146	1.564580	-0.896687	0.026371	-0.220192
147	1.521170	0.269069	-0.180178	-0.119171
148	1.372788	1.011254	-0.933395	-0.026129
149	0.960656	-0.024332	-0.528249	0.163078

[150 rows x 4 columns]

A partir del modelo ACP obtuvimos las proyecciones de cada una de las 150 observaciones sobre los nuevos componentes principales. Estas coordenadas nos permitirán representar gráficamente las observaciones utilizando principalmente PC1 y PC2.

2.9. Mapa de observaciones.

```
# Mapa de observaciones

x = proyecciones.iloc[:,0]
y = proyecciones.iloc[:,1]

z = df.index

x = x.to_numpy()
y = y.to_numpy()


fig, ax = plt.subplots()

ax.set_title("Mapa de observaciones")

ax.scatter(x, y)

colores = {
    'Setosa': 'red',
    'Versicolor': 'blue',
    'Virginica': 'green'}

for i, txt in enumerate(df['variety']):
    ax.annotate(txt,(x[i], y[i]),color=colores[txt])
```



En el mapa de observaciones alcanzamos a distinguir los tres tipos de flores de la base de datos Iris. Lo que podemos observar aquí es que Setosa queda bastante separada de las otras dos especies, formando un clúster más definido. Esto quiere decir que sus características, como el tamaño del pétalo y del sépalo, son lo suficientemente diferentes como para que el ACP la coloque lejos de las demás.

En cambio, Versicolor y Virginica aparecen más cerca entre sí y en algunas partes incluso sus puntos llegan a mezclarse. Esto pasa porque varias de sus medidas son muy parecidas, por lo que no siempre se pueden separar de manera tan clara solo con los dos primeros componentes.

2.10. Mapa de factores.

```
componentes_2 = pd.DataFrame(
    data = modelo_pca.components_,
    columns = df.columns[0:4],
    index = ['PC1', 'PC2', 'PC3', 'PC4'])

componentes_2 = componentes_2.iloc[0:2,:]
componentes_2 = componentes_2.T
componentes_2
```


	PC1	PC2
sepal.length	0.521066	0.377418
sepal.width	-0.269347	0.923296
petal.length	0.580413	0.024492
petal.width	0.564857	0.066942

```
# Mapa de factores
x = componentes_2.iloc[:,0]
y = componentes_2.iloc[:,1]
z = componentes_2.index

x = x.to_numpy()
y = y.to_numpy()

fig, ax = plt.subplots()
ax.set_title("Mapa de factores")
ax.scatter(x, y)

for i, txt in enumerate(z):
    ax.annotate(txt, (x[i], y[i]))
```



El mapa de factores nos ayuda a ver qué tanto influye cada variable en los dos primeros componentes. En este caso, se observa que la longitud y el ancho del pétalo están muy cerca entre sí, lo que significa que se comportan de una forma parecida y que ambas tienen bastante influencia en el primer componente.

También la longitud del sépalo tiene una influencia importante en el PC1, aunque no tanto como las variables del pétalo. En cambio, el ancho del sépalo se relaciona principalmente con el PC2, ya que es la variable que más destaca en ese componente.

2.11. Comparación del mapa de observaciones y el mapa de factores

Al comparar los mapas, se ve que *Setosa* se separa mucho más de las otras especies, mientras que *Versicolor* y *Virginica* aparecen más juntas porque tienen características más parecidas.

Además, el PC1 está más relacionado con el tamaño del pétalo y el PC2 con el ancho del sépalo. Con solo estos dos componentes ya se representa aproximadamente el 95.81% de la información.